

Báo cáo kết quả mô phỏng Cluster-guided Sparse Routing cho MobileNetV3-Small-MoE

Author Name


Ngày 23 tháng 6 năm 2026

1 Mục tiêu mô phỏng

Báo cáo này tổng hợp kết quả mô phỏng cho hướng *Cluster-guided Sparse Routing* trên nền MobileNetV3-Small-MoE. Mục tiêu là kiểm tra liệu cấu trúc cụm trong không gian đặc trưng có thể được dùng như một tín hiệu điều hướng expert hay không. Pipeline mô phỏng gồm: trích xuất đặc trưng, phân cụm trong feature space, xây dựng cluster prototype, định tuyến expert theo độ tương đồng, tổng hợp sparse expert và đánh giá trade-off giữa hiệu năng và chi phí tính toán.

Kết quả sẽ được báo cáo theo các số cluster $G \in \{2, 3, 4, 5, 6, 8\}$.

2 Mô hình đề xuất



Hình 1: Sơ đồ mô hình đề xuất Cluster MoE.

3 Thiết lập thực nghiệm

3.1 Dataset và chia dữ liệu

Bảng 1: Thông tin dataset và số lượng mẫu theo từng split.

Split	Số ảnh	Tỉ lệ train/val/test
Train	2274	80%
Validation	284	10%
Test	285	10%

3.2 Nguồn mã và dữ liệu

Mã nguồn thực nghiệm được công bố tại https://github.com/DoanDucThang0805/Clustering_MoE. Dataset sử dụng trong mô phỏng là Tomato PlantDoc, được lấy từ <https://www.kaggle.com/datasets/cthngon/tomato-plantdoc-mod>.

3.3 Cấu hình chung

Bảng 2: Cấu hình mô phỏng chính.

Thành phần	Cấu hình
Backbone	MobileNetV3-Small
Pretrained model	Không sử dụng; huấn luyện từ đầu (from scratch)
Baseline MoE	MobileNetV3-Small-MoE
Số expert baseline	$E = 4$
Active experts baseline	$\text{top-}k = 2$
Router baseline MoE	Linear gate
Temperature	$\tau = 0.5$
Load balancing coefficient	$\alpha = 0.05$
Seeds	42, 43, 44, 45, 46
Cluster counts	$G \in \{2, 3, 4, 5, 6, 8\}$
Router cluster	Cosine similarity, Euclidean distance

4 Checkpoint 1: Backbone và learned-gate MoE

Bảng 3: Tổng hợp baseline dưới dạng mean $\pm$ std.

Model	Accuracy	Macro-F1	Params(M)	FLOPs(G)
MobileNetV3-Small	0.7656 ± 0.0135	0.7307 ± 0.0170	1.5261	0.1229
MobileNetV3-Small-MoE	0.7839 ± 0.0081	0.7498 ± 0.0122	3.4845	0.1269

Nhận xét. Learned-gate MoE cải thiện so với backbone dense trên cả Accuracy và Macro-F1. Cụ thể, MobileNetV3-Small-MoE đạt Accuracy 0.7839 ± 0.0081 và Macro-F1 0.7498 ± 0.0122 , cao hơn MobileNetV3-Small với Accuracy 0.7656 ± 0.0135 và Macro-F1 0.7307 ± 0.0170 . Mức tăng Macro-F1 khoảng $+0.0191$ cho thấy việc bổ sung nhiều expert và router học được giúp mô hình xử lý tốt hơn các lớp bệnh có độ khó khác nhau. Chi phí tăng chủ yếu nằm ở số tham số, từ 1.5261M lên 3.4845M, trong khi FLOPs chỉ tăng nhẹ từ 0.1229G lên 0.1269G; do đó MoE tạo cải thiện hiệu năng với overhead tính toán tương đối nhỏ.

5 Checkpoint 2: Trích xuất đặc trưng

Với mỗi ảnh x_i , backbone tạo vector đặc trưng:

$$u_i = f_\theta(x_i), \quad u_i \in \mathbb{R}^d. \quad (1)$$

Chỉ feature của tập train được dùng để học cluster center và trực quan hóa cấu trúc phân cụm chính. Lý do là centroid k-means là một thành phần của pipeline huấn luyện/routing prior; nếu dùng validation hoặc test để fit hoặc chọn cluster thì sẽ gây rò rỉ dữ liệu đánh giá vào quá trình thiết kế mô hình. Validation và test vì vậy chỉ được dùng sau khi cluster/prototype đã được học từ train, nhằm đánh giá routing behavior và hiệu năng tổng quát hóa.


6 Checkpoint 3: Feature-space clustering

Với k-means, mỗi feature train được gán vào centroid gần nhất:


$$a_i = \arg \min_{g \in \{1, \dots, G\}} \|u_i - \mu_g\|_2^2. \quad (2)$$

Các centroid μ_g được dùng như routing prototype cho Cluster-MoE.


6.1 Hình phân tích clustering



Hình 2: UMAP của train feature space theo ground-truth class cho cấu hình Cosine với 4 cluster ($G = 4$).



Hình 3: UMAP của train feature space theo cluster assignment cho cấu hình Cosine với 4 cluster ($G = 4$).



Hình 4: Phân bố số mẫu theo 4 cluster của cấu hình Cosine khi dùng k-means với $G = 4$.

Nhận xét. Hai hình UMAP được vẽ trên tập train vì đây là split được dùng để học k-means centroid; do đó trực quan hóa này phản ánh trực tiếp cấu trúc feature mà router cluster sử dụng để tạo prototype. Không dùng validation/test cho bước này để tránh data leakage và giữ hai split đó cho đánh giá độc lập. Trực quan hóa UMAP trên tập train cho thấy feature space đã có cấu trúc tách lớp khá rõ: phần lớn class tạo thành các đảo riêng biệt, ví dụ các nhóm ở vùng trên, vùng trái, vùng phải và vùng dưới của không gian UMAP. Một số vùng có chồng lấn nhẹ giữa các class, nhưng nhìn chung backbone đã học được biểu diễn có tính phân tách tốt trước khi áp dụng cluster-guided routing.

Khi tô màu theo cluster assignment với $G = 4$, k-means gom các đảo class thành bốn prototype lớn hơn thay vì ánh xạ một-một giữa cluster và class. Cluster 1 bao phủ nhiều nhóm ở vùng trên, cluster 2 bao phủ cụm lớn phía trái, cluster 0 bao phủ các nhóm phía dưới và gần trung tâm thấp, còn cluster 3 bao phủ các nhóm ở giữa-phải. Cách gom này phù hợp với mục tiêu routing: cluster là prior theo vùng đặc trưng, không phải nhãn lớp trực tiếp. Do đó, mỗi prototype có thể đại diện cho một nhóm mẫu có hình thái feature gần nhau và điều hướng đến expert phù hợp.

Phân bố cluster với $G = 4$ cho thấy không có cluster rỗng, vì cả bốn cluster đều nhận mẫu sau bước k-means. Tuy nhiên, phân bố chưa cân bằng hoàn toàn: cluster 3 có số mẫu lớn nhất, trong khi cluster 1 và cluster 2 nhỏ hơn đáng kể. Kết hợp với UMAP train, sự mất cân bằng này có thể được giải thích bởi mật độ mẫu khác nhau giữa các vùng feature và việc một số cluster gom nhiều đảo class hơn các cluster còn lại. Việc cấu hình $G = 4$, top- $k = 2$ cho Macro-F1 tốt nhất cho thấy mức phân cụm này đủ thô để ổn định routing, nhưng vẫn đủ chi tiết để khai thác cấu trúc feature space trên tập train.

7 Checkpoint 4: ClusterPrototypeGating

Cosine routing được tính bởi:

$$s_{i,g} = \frac{u_i^T \mu_g}{\|u_i\|_2 \|\mu_g\|_2}, \quad g = 1, \dots, G. \quad (3)$$

Euclidean routing được tính từ khoảng cách đến centroid:

$$s_{i,g} = -\|u_i - \mu_g\|_2^2. \quad (4)$$

Router chọn top- k prototype có score cao nhất, sau đó aggregate sparse experts theo routing weights.

8 Kịch bản mô phỏng chính

Phần này là khung ghi kết quả theo từng kịch bản mô phỏng đang chạy. Các kết quả cần điền tập trung vào learned-gate baseline, Cluster-MoE cosine, Cluster-MoE Euclidean, ablation số cluster và temperature sweep.

8.1 Scenario 1: Learned-Gate Baseline

Mục tiêu của kịch bản này là tạo baseline từ mô hình MobileNetV3-Small-MoE dùng learned gate để so sánh với cluster-guided routing.

Bảng 4: Scenario 1: Learned-gate MoE baseline.

Item	Setting
Backbone	MobileNetV3-Small
Router	linear learned gate
Experts	$E = 4$
top- k	2
Temperature	0.5
Seeds	42, 43, 44, 45, 46
Output	Accuracy, Macro-F1, expert usage

Bảng 5: Tổng hợp kết quả Scenario 1.

Model	Accuracy	Macro-F1	Params (M)	FLOPs (G)
MobileNetV3-Small-MoE	0.7839 ± 0.0081	0.7498 ± 0.0122	3.4845	0.1269

8.2 Scenario 2: Cluster-MoE với Cosine Similarity

Mục tiêu của kịch bản này là kiểm tra định tuyến bằng cosine similarity giữa query feature và cluster centroid.

Bảng 6: Scenario 2: Cluster-guided routing with cosine similarity.

Item	Setting
Backbone	MobileNetV3-Small
Cluster method	k-means trên train features
Clusters	$G = 4$
Router	cluster cosine
top- k	2
Temperature	0.5
Seeds	42, 43, 44, 45, 46
Output	Accuracy, Macro-F1, routing heatmap

Bảng 7: Tổng hợp kết quả Scenario 2.

Model	Accuracy	Macro-F1	Params (M)	FLOPs (G)
Cluster-MoE Cosine	0.8028 ± 0.0240	0.7669 ± 0.0329	3.4772	0.1268

8.3 Scenario 3: Cluster-MoE với Euclidean Distance

Mục tiêu của kịch bản này là kiểm tra định tuyến bằng khoảng cách Euclidean âm từ query feature đến cluster centroid.

Bảng 8: Scenario 3: Cluster-guided routing with Euclidean distance.

Item	Setting
Backbone	MobileNetV3-Small
Cluster method	k-means trên train features
Clusters	$G = 4$
Router	cluster Euclidean
top- k	2
Temperature	0.5
Seeds	42, 43, 44, 45, 46
Output	Accuracy, Macro-F1, routing heatmap

Bảng 9: Tổng hợp kết quả Scenario 3.

Model	Accuracy	Macro-F1	Params (M)	FLOPs (G)
Cluster-MoE Euclidean	0.7382 ± 0.0337	0.6953 ± 0.0304	3.4772	0.1268

8.4 Scenario 4: Ablation số cluster

Mục tiêu của kịch bản này là kiểm tra số cluster/expert phù hợp với dữ liệu. Kết quả mong đợi không phải là G càng lớn càng tốt; khi G quá lớn, mỗi cluster có ít mẫu hơn và routing có thể kém ổn định.

Bảng 10: Scenario 4: Cluster-number ablation.

Clusters	G	top- k	Routing metric
	2	1	Cosine, Euclidean
	3	1	Cosine, Euclidean
	4	1, 2	Cosine, Euclidean
	5	1, 2	Cosine, Euclidean
	6	1, 2, 3	Cosine, Euclidean
	8	1, 2, 3, 4	Cosine, Euclidean

Bảng 11: Kết quả Scenario 4: ablation theo G và top- k với Cosine similarity.

G	top- k	Accuracy	Macro-F1
2	1	0.7691 ± 0.0325	0.7346 ± 0.0307
2	2	0.7523 ± 0.0091	0.7169 ± 0.0114
3	1	0.7558 ± 0.0420	0.7147 ± 0.0450
3	2	0.7811 ± 0.0346	0.7487 ± 0.0371
4	1	0.7796 ± 0.0247	0.7437 ± 0.0269
4	2	0.8028 ± 0.0240	0.7669 ± 0.0329
5	1	0.7775 ± 0.0156	0.7371 ± 0.0140
5	2	0.7663 ± 0.0205	0.7290 ± 0.0235
5	3	0.7811 ± 0.0338	0.7428 ± 0.0432
6	1	0.7670 ± 0.0214	0.7302 ± 0.0242
6	2	0.7530 ± 0.0324	0.7167 ± 0.0339
6	3	0.7740 ± 0.0180	0.7372 ± 0.0167
8	1	0.7782 ± 0.0257	0.7379 ± 0.0361
8	2	0.7691 ± 0.0583	0.7312 ± 0.0638
8	3	0.7775 ± 0.0263	0.7389 ± 0.0281
8	4	0.7888 ± 0.0204	0.7577 ± 0.0256

Bảng 12: Kết quả Scenario 4: ablation theo G và top- k với Euclidean distance.

G	top- k	Accuracy	Macro-F1
2	1	0.7600 ± 0.0335	0.7253 ± 0.0389
2	2	0.7832 ± 0.0307	0.7447 ± 0.0348
3	1	0.7754 ± 0.0323	0.7420 ± 0.0343
3	2	0.7761 ± 0.0163	0.7352 ± 0.0206
4	1	0.7628 ± 0.0350	0.7240 ± 0.0368
4	2	0.7382 ± 0.0337	0.6953 ± 0.0304
5	1	0.7600 ± 0.0250	0.7277 ± 0.0268
5	2	0.7614 ± 0.0428	0.7175 ± 0.0487
5	3	0.7832 ± 0.0150	0.7511 ± 0.0189
6	1	0.7825 ± 0.0275	0.7477 ± 0.0301
6	2	0.7263 ± 0.0511	0.6878 ± 0.0532
6	3	0.7460 ± 0.0574	0.7149 ± 0.0553
8	1	0.7719 ± 0.0260	0.7409 ± 0.0306
8	2	0.7719 ± 0.0170	0.7396 ± 0.0208
8	3	0.7600 ± 0.0205	0.7264 ± 0.0213
8	4	0.7551 ± 0.0368	0.7186 ± 0.0427

Nhận xét. Kết quả ablation tại $\tau = 0.5$ cho thấy cấu hình tốt nhất hiện tại là Cluster-MoE dùng Cosine similarity với $G = 4$ và top- $k = 2$, đạt Accuracy 0.8028 ± 0.0240 và Macro-F1 0.7669 ± 0.0329 . Điều này cho thấy metric Cosine phù hợp hơn cho bước temperature sweep, vì nó tạo cấu hình có Macro-F1 cao nhất trong toàn bộ grid.

8.5 Scenario 5: Temperature Sweep

Mục tiêu của kịch bản này là kiểm tra độ sắc của similarity-guided routing khi thay đổi temperature τ . Do metric Cosine đang cho kết quả tốt nhất, temperature sweep được thực hiện trên router Cosine thay vì chạy lại cả hai metric.

Bảng 13: Scenario 5: Temperature sweep for cluster routing.

Temperature τ	Router	Expected effect
0.3	Cosine	Routing sắc hơn, dễ ưu tiên một expert
0.5	Cosine	Cấu hình mặc định, cân bằng
0.7	Cosine	Routing mềm hơn
1.0	Cosine	Expert weights phân tán hơn

Bảng 14: Kết quả Scenario 5 theo temperature trên metric Cosine tốt nhất.

τ	Accuracy	Macro-F1	Best seed/config
0.3	0.7656 ± 0.0287	0.7276 ± 0.0282	Cosine, $G = 4$, top- $k = 2$
0.5	0.8028 ± 0.0240	0.7669 ± 0.0329	Cosine, $G = 4$, top- $k = 2$
0.7	0.7712 ± 0.0135	0.7307 ± 0.0163	Cosine, $G = 4$, top- $k = 2$
1.0	0.7832 ± 0.0381	0.7484 ± 0.0393	Cosine, $G = 4$, top- $k = 2$

Nhận xét. Temperature sweep cho thấy $\tau = 0.5$ là lựa chọn tốt nhất trong các giá trị đã thử, đạt Accuracy 0.8028 ± 0.0240 và Macro-F1 0.7669 ± 0.0329 . Khi $\tau = 0.3$, routing sắc hơn nhưng Macro-F1 giảm xuống 0.7276 ± 0.0282 , cho thấy việc tập trung quá mạnh vào một vài prototype có thể làm giảm khả năng tổng hợp thông tin giữa expert. Khi tăng temperature lên 0.7 và 1.0, kết quả có cải thiện so với $\tau = 0.3$ nhưng vẫn thấp hơn $\tau = 0.5$. Vì vậy, cấu hình Cosine với $G = 4$, top- $k = 2$, $\tau = 0.5$ là điểm cân bằng tốt nhất giữa độ sắc và độ mềm của routing.

8.6 Scenario 6: Deploy on Pi5

Mục tiêu của kịch bản này là kiểm tra chi phí triển khai thực tế của backbone, learned-gate MoE và Cluster-MoE trên Raspberry Pi 5. Các chỉ số được ghi nhận gồm kích thước mô hình, bộ nhớ CPU đỉnh và thời gian suy luận CPU.

Bảng 15: Scenario 6: Benchmark triển khai trên Raspberry Pi 5.

Model	Model size (MB)	CPU peak memory (MB)	CPU inference time (ms)
MobileNetV3-Small	6.1006	81.4219	6.2622
MobileNetV3-Small-MoE	22.7311	98.8125	8.2498
Cluster-MoE	22.7014	100.1719	7.9588

Nhận xét. Kết quả trên Raspberry Pi 5 cho thấy Cluster-MoE có kích thước mô hình gần tương

đương learned-gate MoE, lần lượt 22.7014MB và 22.7311MB, nhưng thời gian suy luận CPU thấp hơn nhẹ, 7.9588ms so với 8.2498ms. So với MobileNetV3-Small dense, Cluster-MoE tăng kích thước mô hình và bộ nhớ đỉnh do có nhiều expert hơn, nhưng vẫn giữ thời gian suy luận dưới 8ms. Điều này cho thấy cấu hình Cluster-MoE tốt nhất không chỉ cải thiện Macro-F1 mà còn duy trì latency khả thi trên thiết bị biên như Pi 5.

9 Checkpoint 5: Cluster-MoE grid

Bảng 16: Kết quả Cluster-MoE theo G , routing score và top- k dưới dạng mean $\pm$ std.

G	Routing score	top- k	Accuracy	Macro-F1	Params	FLOPs
2	Cosine	1	0.7691 ± 0.0325	0.7346 ± 0.0307	3.4772	0.1268
2	Cosine	2	0.7523 ± 0.0091	0.7169 ± 0.0114	3.4772	0.1268
2	Euclidean	1	0.7600 ± 0.0335	0.7253 ± 0.0389	3.4772	0.1268
2	Euclidean	2	0.7832 ± 0.0307	0.7447 ± 0.0348	3.4772	0.1268
3	Cosine	1	0.7558 ± 0.0420	0.7147 ± 0.0450	3.4772	0.1268
3	Cosine	2	0.7811 ± 0.0346	0.7487 ± 0.0371	3.4772	0.1268
3	Euclidean	1	0.7754 ± 0.0323	0.7420 ± 0.0343	3.4772	0.1268
3	Euclidean	2	0.7761 ± 0.0163	0.7352 ± 0.0206	3.4772	0.1268
4	Cosine	1	0.7796 ± 0.0247	0.7437 ± 0.0269	3.4772	0.1268
4	Cosine	2	0.8028 ± 0.0240	0.7669 ± 0.0329	3.4772	0.1268
4	Euclidean	1	0.7628 ± 0.0350	0.7240 ± 0.0368	3.4772	0.1268
4	Euclidean	2	0.7382 ± 0.0337	0.6953 ± 0.0304	3.4772	0.1268
5	Cosine	1	0.7775 ± 0.0156	0.7371 ± 0.0140	3.4772	0.1268
5	Cosine	2	0.7663 ± 0.0205	0.7290 ± 0.0235	3.4772	0.1268
5	Cosine	3	0.7811 ± 0.0338	0.7428 ± 0.0432	3.4772	0.1268
5	Euclidean	1	0.7600 ± 0.0250	0.7277 ± 0.0268	3.4772	0.1268
5	Euclidean	2	0.7614 ± 0.0428	0.7175 ± 0.0487	3.4772	0.1268
5	Euclidean	3	0.7832 ± 0.0150	0.7511 ± 0.0189	3.4772	0.1268
6	Cosine	1	0.7670 ± 0.0214	0.7302 ± 0.0242	3.4772	0.1268
6	Cosine	2	0.7530 ± 0.0324	0.7167 ± 0.0339	3.4772	0.1268
6	Cosine	3	0.7740 ± 0.0180	0.7372 ± 0.0167	3.4772	0.1268
6	Euclidean	1	0.7825 ± 0.0275	0.7477 ± 0.0301	3.4772	0.1268
6	Euclidean	2	0.7263 ± 0.0511	0.6878 ± 0.0532	3.4772	0.1268
6	Euclidean	3	0.7460 ± 0.0574	0.7149 ± 0.0553	3.4772	0.1268
8	Cosine	1	0.7782 ± 0.0257	0.7379 ± 0.0361	3.4772	0.1268
8	Cosine	2	0.7691 ± 0.0583	0.7312 ± 0.0638	3.4772	0.1268
8	Cosine	3	0.7775 ± 0.0263	0.7389 ± 0.0281	3.4772	0.1268
8	Cosine	4	0.7888 ± 0.0204	0.7577 ± 0.0256	3.4772	0.1268
8	Euclidean	1	0.7719 ± 0.0260	0.7409 ± 0.0306	3.4772	0.1268
8	Euclidean	2	0.7719 ± 0.0170	0.7396 ± 0.0208	3.4772	0.1268
8	Euclidean	3	0.7600 ± 0.0205	0.7264 ± 0.0213	3.4772	0.1268
8	Euclidean	4	0.7551 ± 0.0368	0.7186 ± 0.0427	3.4772	0.1268

Nhận xét. Trong grid tại $\tau = 0.5$, cấu hình tốt nhất là Cosine với $G = 4$ và top- $k = 2$, đạt Macro-F1 0.7669 ± 0.0329 . So với Euclidean tốt nhất trong grid ($G = 5$, top- $k = 3$, Macro-F1 0.7511 ± 0.0189), Cosine cho kết quả cao hơn. Khi tăng G quá lớn, hiệu năng không tăng đều; ví dụ Cosine với $G = 8$, top- $k = 4$ đạt Macro-F1 0.7577 ± 0.0256 , thấp hơn cấu hình $G = 4$, top- $k = 2$.


Điều này gợi ý rằng số prototype vừa phải giúp routing ổn định hơn.

10 Bảng kết quả so sánh hiệu năng

Bảng 17: Comparison of learned and cluster-guided sparse routing.


Model	Expert source	Routing score	E/G	top- k	Macro-F1	Params (M)	FLOPs (G)
MobileNetV3-Small	–	Dense head	–	–	0.7307 ± 0.0170	1.5261	0.1229
MobileNetV3-Small-MoE	Learned experts	Linear learned gate	4	2	0.7498 ± 0.0122	3.4845	0.1269
Cluster-MoE	k-means clusters	Cosine similarity	4	2	0.7669 ± 0.0329	3.4772	0.1268
Cluster-MoE	k-means clusters	Euclidean distance	4	2	0.6953 ± 0.0304	3.4772	0.1268

11 Phân tích mức sử dụng expert trên tập test




Hình 5: Tỷ lệ sử dụng từng expert của learned-gate MoE trên tập test. Giá trị đã được chuẩn hóa về phần trăm.

Nhận xét. Hình trên biểu diễn tỷ lệ phần trăm số lần mỗi expert được router lựa chọn khi learned-gate MoE suy luận trên tập test. Với bốn expert, nếu router phân bổ hoàn toàn đồng đều thì mỗi expert sẽ xấp xỉ 25% tổng số lượt chọn. Quan sát cho thấy cả bốn expert đều có tỷ lệ sử dụng khác 0, vì vậy router không bị collapse về một expert duy nhất. Về hành vi phân bổ, Expert 2 và Expert 3 nằm tương đối gần mốc 25%, Expert 4 được chọn nhiều hơn, còn Expert 1 có tỷ lệ thấp nhất. Điều này cho thấy learned gate vẫn duy trì việc sử dụng nhiều expert trên tập test, nhưng lựa chọn của router không đồng đều tuyệt đối mà có xu hướng ưu tiên một số expert hơn các expert còn lại.




Hình 6: Heatmap tỉ lệ kích hoạt expert theo từng lớp của learned-gate MoE trên tập test.

Nhận xét. Heatmap class-wise cho thấy learned-gate router hình thành xu hướng chuyên môn hóa mềm giữa các expert trên tập test. Các giá trị trong từng hàng biểu diễn tỉ lệ kích hoạt expert đối với một lớp cụ thể, do đó có thể quan sát expert nào được router ưu tiên cho từng nhóm mẫu. Một số lớp có expert chiếm ưu thế rõ ràng: *Tomato Septoria leaf spot* và *Tomato leaf bacterial spot* kích hoạt mạnh Expert 4, *Tomato leaf yellow virus* tập trung nhiều vào Expert 3, còn *Tomato leaf* ưu tiên Expert 2. Điều này cho thấy router không phân bổ mẫu hoàn toàn ngẫu nhiên, mà học được xu hướng gán các lớp hoặc nhóm đặc trưng khác nhau cho các expert khác nhau. Tuy nhiên, sự chuyên môn hóa này không phải ánh xạ cứng một-lớp-một-expert, vì hầu hết các lớp vẫn có activation rate đáng kể ở nhiều expert. Ví dụ, *Tomato leaf late blight* có tỉ lệ tương đối cân bằng giữa Expert 2 và Expert 4, trong khi *Tomato mold leaf* được chia sẻ giữa nhiều expert. Do đó, learned-gate MoE thể hiện cơ chế *soft specialization*: một số expert có xu hướng phụ trách nổi bật hơn cho một số lớp, nhưng vẫn tồn tại sự chia sẻ routing giữa các expert. Đồng thời, vì tất cả expert đều xuất hiện trong heatmap với tỉ lệ kích hoạt khác 0, kết quả này không cho thấy hiện tượng collapse router.



Hình 7: Tỷ lệ sử dụng từng expert của Cluster-MoE trên tập test. Giá trị đã được chuẩn hóa về phần trăm.


Nhận xét. Đối với Cluster-MoE, hình trên cũng biểu diễn tỷ lệ phần trăm số lần mỗi expert được router lựa chọn trên tập test. Tất cả expert đều có tỷ lệ sử dụng khác 0, do đó không xuất hiện hiện tượng collapse hoàn toàn về một expert duy nhất. So với mức phân bổ đều 25% cho mỗi expert, Expert 1 có tỷ lệ lựa chọn cao nhất, Expert 4 đứng thứ hai, trong khi Expert 2 và Expert 3 được chọn ít hơn. Như vậy, hành vi routing của Cluster-MoE có tính tập trung hơn learned-gate MoE: router vẫn sử dụng toàn bộ expert, nhưng phân bổ lượt chọn không đồng đều giữa các expert. Quan sát này mô tả đặc điểm hoạt động của router trên tập test, cụ thể là có sự ưu tiên rõ hơn cho một số expert, nhưng chưa cho thấy dấu hiệu collapse vì không expert nào bị bỏ qua hoàn toàn.



Hình 8: Heatmap tỉ lệ kích hoạt expert theo từng lớp của Cluster-MoE trên tập test.


Nhận xét. Heatmap class-wise của Cluster-MoE cho thấy hành vi routing theo lớp có mức chuyên môn hóa rõ hơn so với phân bố tổng thể. Expert 1 được kích hoạt rất mạnh ở nhiều lớp, bao gồm *Tomato Early blight leaf*, *Tomato Septoria leaf spot*, *Tomato leaf*, *Tomato leaf bacterial spot*, *Tomato leaf late blight* và *Tomato mold leaf*. Điều này cho thấy một prototype/expert có vai trò nổi bật đối với nhiều vùng đặc trưng trên tập test. Bên cạnh đó, một số lớp vẫn thể hiện xu hướng chuyên biệt khác: *Tomato leaf mosaic virus* kích hoạt mạnh Expert 4, trong khi *Tomato leaf yellow virus* cũng ưu tiên Expert 4 và có mức kích hoạt đáng kể ở Expert 2. *Tomato leaf bacterial spot* ngoài Expert 1 còn có activation rate cao ở Expert 3, cho thấy lớp này được chia sẻ giữa hai expert chính. Như vậy, Cluster-MoE không tạo ánh xạ cứng một-lớp-một-expert, mà hình thành cơ chế *soft specialization* dựa trên prototype: một số expert được ưu tiên mạnh cho nhiều lớp hoặc nhóm lớp, trong khi các expert khác vẫn tham gia ở những lớp nhất định. Vì tất cả expert đều có vùng kích hoạt khác 0 trên heatmap, kết quả này không cho thấy collapse router; thay vào đó, nó cho thấy router cluster có xu hướng tập trung hơn vào các expert/prototype nổi bật.

12 Phân tích ma trận nhầm lẫn của MoE baseline trên tập test



Hình 9: Confusion matrix của MoE baseline dùng learned gate trên tập test.

Nhận xét. Confusion matrix của MoE baseline dùng learned gate cho thấy phần lớn mẫu nằm trên đường chéo chính, tức là mô hình dự đoán đúng phần lớn ảnh test ở hầu hết các lớp. Lớp *Tomato leaf yellow virus* có số dự đoán đúng cao nhất với 74 mẫu, cho thấy đây là lớp được MoE baseline nhận diện ổn định nhất trong tập test hiện tại. Các lớp *Tomato leaf*, *Tomato Septoria leaf spot*, *Tomato leaf bacterial spot*, *Tomato leaf late blight*, *Tomato leaf mosaic virus* và *Tomato mold leaf* cũng có phần lớn mẫu nằm trên đường chéo, nhưng vẫn xuất hiện một số nhầm lẫn cục bộ. Một số cặp dễ nhầm đáng chú ý gồm *Tomato mold leaf* bị dự đoán thành *Tomato leaf yellow virus*, *Tomato Septoria leaf spot* bị nhầm sang *Tomato leaf bacterial spot*, và *Tomato leaf mosaic virus* bị nhầm sang *Tomato leaf yellow virus*. Ngoài ra, *Tomato Early blight leaf* có số mẫu đúng thấp hơn tương đối so với một số lớp khác và bị phân tán sang nhiều nhãn dự đoán, cho thấy lớp này có biên quyết định kém tập trung hơn. Nhìn chung, ma trận nhầm lẫn cho thấy MoE baseline đã học được cấu trúc phân biệt chính giữa các lớp, nhưng các lỗi còn lại chủ yếu xảy ra giữa những lớp có biểu hiện thị giác hoặc đặc trưng lá dễ chồng lẫn.



Hình 10: Confusion matrix của Cluster-MoE trên tập test.

Nhận xét. Confusion matrix của Cluster-MoE cũng cho thấy phần lớn dự đoán nằm trên đường chéo chính, phản ánh rằng mô hình vẫn giữ được khả năng phân biệt chính giữa các lớp trên tập test. So với MoE baseline, một số lớp có số mẫu đúng cao hơn, chẳng hạn *Tomato Early blight leaf* tăng lên 15 mẫu đúng, *Tomato Septoria leaf spot* đạt 35 mẫu đúng, *Tomato leaf* đạt 36 mẫu đúng, *Tomato leaf mosaic virus* đạt 22 mẫu đúng và *Tomato leaf yellow virus* đạt 76 mẫu đúng. Điều này cho thấy Cluster-MoE cải thiện số dự đoán đúng ở nhiều lớp so với baseline learned-gate. Tuy nhiên, ma trận cũng cho thấy một số nhầm lẫn vẫn còn tồn tại. Đáng chú ý nhất là *Tomato leaf bacterial spot* bị nhầm sang *Tomato Septoria leaf spot* với 7 mẫu, cho thấy hai lớp này vẫn có vùng đặc trưng dễ chồng lẫn. Ngoài ra, *Tomato mold leaf* vẫn còn bị nhầm sang *Tomato leaf yellow virus*, dù số lỗi giảm so với MoE baseline. Nhìn chung, Cluster-MoE tạo đường chéo chính rõ và cải thiện một số lớp, trong khi các lỗi còn lại chủ yếu tập trung ở các cặp bệnh có biểu hiện thị giác gần nhau.

13 Kết luận tạm thời

Kết quả hiện tại cho thấy cấu hình tốt nhất là Cluster-MoE dùng Cosine similarity với $G = 4$, $\text{top-}k = 2$ và $\tau = 0.5$, đạt Accuracy 0.8028 ± 0.0240 và Macro-F1 0.7669 ± 0.0329 . So với MobileNetV3-

Small, cấu hình này tăng Macro-F1 từ 0.7307 lên 0.7669, tương ứng mức cải thiện khoảng +0.0362. So với learned-gate MoE, Macro-F1 tăng từ 0.7498 lên 0.7669, tương ứng khoảng +0.0171. Euclidean routing kém ổn định hơn trong cấu hình chính $G = 4$, top- $k = 2$, chỉ đạt Macro-F1 0.6953 ± 0.0304 , cho thấy metric khoảng cách chưa phù hợp bằng Cosine trong feature space hiện tại. Do đó, cấu hình khuyến nghị để đưa vào bài viết là Cluster-MoE Cosine, $G = 4$, top- $k = 2$, $\tau = 0.5$, huấn luyện từ đầu không dùng pretrained model.