

Hướng Dẫn Mô Phỏng Bổ Sung cho Clustered Mixture-of-Experts Routing

Tài liệu nội bộ cho triển khai và bổ sung kết quả bài báo

Tóm tắt nội dung

Tài liệu này mô tả các mô phỏng bổ sung cần thực hiện cho bài báo *Clustered Mixture-of-Experts Routing for Edge Image Classification*. Mục tiêu là xử lý sáu điểm còn yếu của bản hiện tại: huấn luyện từ đầu, một dataset, số seed nhỏ, thiếu routing entropy, thiếu baseline mạnh, và thiếu ablation để kiểm chứng vai trò của từng expert. Hướng dẫn tập trung vào các checkpoint thực thi, các file CSV cần xuất, và cách ánh xạ kết quả vào bảng/hình trong bản thảo IEEE.

Index Terms

Edge image classification, clustered MoE routing, active computational cost, routing entropy, expert ablation, pretrained backbone, multi-seed evaluation.

I. Mục tiêu bổ sung

Bản hiện tại đã chứng minh cấu hình Cluster-MoE cosine với $G = 4$, $\text{top-}k = 2$, và $\tau = 0.5$ là điểm vận hành tốt nhất trong grid ban đầu. Tuy nhiên, kết luận vẫn bị giới hạn bởi ba yếu tố chính: feature encoder được huấn luyện từ đầu trên tập train nhỏ, chỉ có một dataset PlantDoc-derived tomato subset, và số seed $n = 5$ chưa đủ power thống kê.

Mục tiêu của đợt mô phỏng bổ sung là không mở rộng vô hạn toàn bộ grid, mà kiểm tra có kiểm soát các cấu hình chốt. Cấu hình trọng tâm là:

$$\text{Cluster-MoE cosine, } G = 4, \quad k = 2, \quad \tau = 0.5. \quad (1)$$

Cấu hình này là điểm tham chiếu chính để kiểm tra pretrained backbone, routing entropy, expert ablation, tăng số seed, dataset độc lập, và backbone thay thế.

II. Nguyên tắc thực nghiệm

Tất cả mô phỏng bổ sung phải tuân thủ bốn nguyên tắc. Thứ nhất, centroid clustering chỉ được fit trên train features; validation và test không được dùng để học centroid. Thứ hai, khi đổi backbone hoặc pretrained state, phải trích xuất lại features và fit lại centroid; không dùng lại centroid của cấu hình cũ. Thứ ba, mọi so sánh chính phải dùng cùng seed list và cùng data split. Thứ tư, claim về giảm phức tạp phải viết là giảm hoặc kiểm soát *active computational cost*, không viết là giảm tổng tham số.

III. Checkpoint tổng quát

Bảng I
Các checkpoint bắt buộc trước khi cập nhật kết quả vào bài báo.

Checkpoint	Nội dung cần hoàn thành	File xác nhận
CP0	Khóa kết quả pilot hiện có: dense MobileNetV3-Small, learned-gate MoE, Cluster-MoE cosine/Euclidean, grid G, k , temperature sweep, Pi 5 runtime.	pilot_summary.csv
CP1	Chạy ImageNet-pretrained MobileNetV3-Small cho dense, learned-gate MoE, và Cluster-MoE cosine.	pretrained_backbone_results.csv
CP2	Tính routing entropy, normalized entropy và expert-usage concentration từ routing records.	routing_entropy.csv
CP3	Chạy expert masking ablation và conditional confusion matrix theo primary expert.	expert_masking_ablation.csv, conditional_confusion_summary.csv
CP4	Tăng số seed cho ba cấu hình chính hoặc thực hiện power analysis từ paired differences.	seedwise_main_results.csv, power_analysis.csv
CP5	Chạy ít nhất một dataset độc lập để kiểm tra khả năng tổng quát.	cross_dataset_results.csv
CP6	Chạy ít nhất một backbone thay thế, ưu tiên MobileNetV2 hoặc EfficientNet-B0.	backbone_generalization.csv
CP7	Nếu giữ Soft MoE như baseline gần, cần implement hoặc hạ xuống Related Work.	soft_moe_baseline.csv hoặc ghi chú loại khỏi baseline

IV. CP1: Kiểm tra ImageNet-pretrained backbone

A. Mục tiêu

Mục tiêu là xác nhận Cluster-MoE không phụ thuộc vào feature space kém chất lượng do huấn luyện từ đầu trên tập train nhỏ. Với backbone pretrained, feature vector thường có cấu trúc ổn định hơn, nên centroid k-means có thể đại diện tốt hơn cho các vùng đặc trưng.

B. Cấu hình chạy

Bảng II
Cấu hình tối thiểu cho thí nghiệm pretrained backbone.

Thành phần	Cấu hình
Backbone	MobileNetV3-Small
Initialization	From scratch; ImageNet-pretrained
Models	Dense; learned-gate MoE; Cluster-MoE cosine
Cluster-MoE	$G = 4$, $\text{top-}k = 2$, $\tau = 0.5$
Seeds	{42, 43, 44, 45, 46} cho pilot; 10 hoặc 20 seeds nếu đủ thời gian
Metrics	Accuracy, Macro-F1, Weighted-F1, Params, FLOPs, latency

C. CSV cần xuất

```
# pretrained_backbone_results.csv
seed,initialization,backbone,model,routing,cluster_method,G,top_k,tau,
accuracy,macro_f1,weighted_f1,params_m,flops_g,model_size_mb,
peak_cpu_memory_mb,cpu_latency_ms
```

D. Bảng đưa vào bài

Table: Effect of backbone initialization on dense, learned-gate MoE, and Cluster-MoE.
 Rows: from-scratch vs ImageNet-pretrained.
 Main claim: Cluster-MoE remains competitive when the feature encoder is initialized from a practical pretrained checkpoint.

V. CP2: Báo cáo routing entropy

A. Mục tiêu

Bài hiện đã định nghĩa routing entropy, nhưng chưa báo cáo giá trị. Đây là thiếu sót vì entropy phân biệt routing sắc và routing phân tán. Với $\text{top-}k = 2$, entropy chuẩn hóa nên được báo cáo để so sánh giữa learned-gate MoE và Cluster-MoE.

Routing entropy của mẫu i là:

$$H_i = - \sum_{g \in \mathcal{K}_i} \alpha_{i,g} \log(\alpha_{i,g} + \epsilon). \quad (2)$$

Giá trị này đo độ tập trung của trọng số expert. H_i thấp nghĩa là router gần như chọn một expert chính; H_i cao nghĩa là hai expert được trộn gần đều.

Entropy trung bình và entropy chuẩn hóa là:

$$\bar{H} = \frac{1}{N} \sum_{i=1}^N H_i, \quad H_{\text{norm}} = \frac{\bar{H}}{\log k}. \quad (3)$$

H_{norm} cho phép so sánh giữa các cấu hình có $\text{top-}k$ khác nhau.

B. CSV cần xuất

```
# routing_entropy.csv
seed,model,routing,G,top_k,tau,split,
mean_entropy,std_entropy,normalized_entropy,
expert_usage_1,expert_usage_2,expert_usage_3,expert_usage_4,
usage_cv,accuracy,macro_f1
```

C. Hình và bảng cần đưa vào bài

Cần một bảng entropy và một hình đường cong. Bảng báo cáo $\bar{H}$ theo model và τ . Hình nên đặt Macro-F1 và normalized entropy theo τ trên cùng trục hoành. Nếu $\tau = 0.5$ đạt Macro-F1 tốt nhất, phần giải thích phải chỉ ra đây là điểm cân bằng giữa routing quá sắc và routing quá mềm.

VI. CP3: Expert masking ablation

A. Mục tiêu

Heatmap class-wise hiện chỉ cho thấy routing có cấu trúc quan sát được. Nó chưa đủ để chứng minh expert specialization. Expert masking là kiểm tra can thiệp ở inference: tắt từng expert và đo suy giảm hiệu năng.

Với expert g bị mask, nếu $g \in \mathcal{K}_i$ thì đặt $\alpha_{i,g} = 0$ và chuẩn hóa lại các trọng số còn lại:

$$\tilde{\alpha}_{i,j} = \frac{\alpha_{i,j} \mathbf{1}(j \neq g)}{\sum_{\ell \in \mathcal{K}_i, \ell \neq g} \alpha_{i,\ell} + \epsilon}. \quad (4)$$

Phương trình này đo vai trò của expert g trong forward path mà không cần huấn luyện lại mô hình.

B. CSV cần xuất

```
# expert_masking_ablation.csv
seed,model,routing,G,top_k,tau,mask_expert,
accuracy,macro_f1,weighted_f1,
delta_accuracy,delta_macro_f1,delta_weighted_f1,
class_0_f1,class_1_f1,class_2_f1,class_3_f1,
class_4_f1,class_5_f1,class_6_f1,class_7_f1
```

```
# conditional_confusion_summary.csv
seed,model,routing,G,top_k,tau,primary_expert,
num_samples,accuracy,macro_f1,
most_confused_pair,most_confused_count,
class_0_recall,class_1_recall,class_2_recall,class_3_recall,
class_4_recall,class_5_recall,class_6_recall,class_7_recall
```

C. Điều kiện claim

Nếu mask một expert làm giảm mạnh Macro-F1 hoặc giảm rõ F1 của một nhóm class, có thể viết: expert đó có đóng góp lớn cho vùng đặc trưng tương ứng. Nếu không có suy giảm rõ, chỉ viết: router có phân bổ có cấu trúc, chưa đủ bằng chứng can thiệp cho specialization.

VII. CP4: Tăng số seed và power analysis

A. Mục tiêu

Với $n = 5$ seeds, paired tests dễ không có ý nghĩa thống kê sau Holm correction. Cần tăng seed cho các cấu hình chốt hoặc báo cáo power analysis để chứng minh kích thước mẫu hiện tại chưa đủ.

B. Cấu hình cần chạy

Không tăng seed cho toàn bộ grid. Chỉ chạy:

- 1) Dense MobileNetV3-Small.
- 2) Learned-gate MoE, $E = 4$, top- $k = 2$.
- 3) Cluster-MoE cosine, $G = 4$, top- $k = 2$, $\tau = 0.5$.
- 4) Tùy chọn: Cluster-MoE Euclidean best point nếu muốn phân tích metric sensitivity.

C. CSV cần xuất

```
# seedwise_main_results.csv
seed,dataset,initialization,backbone,model,routing,G,top_k,tau,
accuracy,macro_f1,weighted_f1,params_m,flops_g,latency_ms
```

```
# paired_statistics_extended.csv
metric,model_a,model_b,n_seeds,mean_a,mean_b,mean_diff,
std_diff,ci95_low,ci95_high,paired_t_p,wilcoxon_p,
holm_p,bh_p,effect_size_dz
```

```
# power_analysis.csv
comparison,metric,alpha,power_target,pilot_mean_diff,pilot_std_diff,
effect_size_dz,required_n_uncorrected,required_n_holm,
current_n,decision
```

D. Công thức power analysis

Số seed tối thiểu cho paired comparison được ước lượng bởi:

$$n_{\min} = \left(\frac{z_{1-\alpha/2} + z_{1-\beta}}{\Delta/\sigma_d} \right)^2, \quad (5)$$

trong đó Δ là mean paired difference, σ_d là độ lệch chuẩn của paired differences, α là mức ý nghĩa, và $1 - \beta$ là statistical power mục tiêu. Nếu có m so sánh chính và dùng Holm correction, dùng gần đúng $\alpha' = \alpha/m$.

VIII. CP5: Dataset độc lập

A. Mục tiêu

Một dataset duy nhất không đủ để phân biệt hiệu quả của phương pháp với đặc tính riêng của PlantDoc-derived tomato subset. Cần thêm một dataset độc lập để kiểm tra tính tổng quát của clustered MoE routing.

B. Lựa chọn dataset

Ưu tiên theo thứ tự:

- 1) PlantVillage tomato subset: dễ chạy, cùng miền, kiểm tra điều kiện ảnh sạch hơn.
- 2) Cassava Leaf Disease hoặc một dataset plant disease độc lập: tốt hơn cho tính tổng quát vì khác crop và khác phân bố ảnh.
- 3) CIFAR-10/CIFAR-100: chỉ dùng như sanity check cho edge image classification, không phải kết quả ứng dụng chính.

C. CSV cần xuất

```
# cross_dataset_results.csv
seed,dataset,num_classes,num_train,num_val,num_test,
backbone,initialization,model,routing,G,top_k,tau,
accuracy,macro_f1,weighted_f1,params_m,flops_g,latency_ms
```

IX. CP6: Backbone thay thế

A. Mục tiêu

Cần kiểm tra Cluster-MoE không phải artifact của MobileNetV3-Small. Tối thiểu chạy một backbone thay thế. Nếu nhấn edge, chọn MobileNetV2. Nếu muốn baseline mạnh hơn, chọn EfficientNet-B0.

B. Cấu hình tối thiểu

Bảng III
Backbone generalization tối thiểu.

Backbone	Models cần chạy	Ghi chú
MobileNetV3-Small	Dense, learned-gate MoE, Cluster-MoE	Đã có pilot
MobileNetV2	Dense, learned-gate MoE, Cluster-MoE	Edge baseline gần nhất
EfficientNet-B0	Dense, learned-gate MoE, Cluster-MoE	Baseline mạnh hơn, tùy thời gian

C. CSV cần xuất

```
# backbone_generalization.csv
seed,dataset,backbone,initialization,model,routing,G,top_k,tau,
accuracy,macro_f1,weighted_f1,params_m,flops_g,
model_size_mb,peak_cpu_memory_mb,cpu_latency_ms
```

X. CP7: Soft MoE baseline

Nếu bài giữ Soft MoE là baseline gần trong Related Work, cần một trong hai xử lý. Phương án tốt nhất là implement Soft MoE classifier-side với cùng backbone, số expert và training budget. Nếu chưa implement, không đưa Soft MoE vào bảng baseline chính; chỉ thảo luận trong Related Work và nêu rõ khác biệt: Soft MoE dùng cơ chế soft assignment, còn bài này kiểm tra cluster-prototype top- k routing cho classifier-side expert selection.

```
# soft_moe_baseline.csv (optional)
seed,dataset,backbone,model,num_experts,routing_type,
accuracy,macro_f1,weighted_f1,params_m,flops_g,latency_ms
```

XI. Thứ tự chạy khuyến nghị

Bảng IV
Thứ tự triển khai để giảm rủi ro mô phỏng.

Ưu tiên	Việc cần làm	Lý do
1	Tính routing entropy từ checkpoint hiện có	Không cần retrain, vá lỗi hỏng metric
2	Expert masking và conditional confusion	Không cần retrain, kiểm chứng vai trò expert
3	ImageNet-pretrained MobileNetV3-Small	Xử lý điểm yếu train-from-scratch
4	Tăng seed lên 10 cho ba model chính	Tăng power thống kê
5	Dataset độc lập	Kiểm tra tính tổng quát
6	Backbone thay thế	Kiểm tra cơ chế routing không phụ thuộc backbone
7	Soft MoE baseline	Chỉ cần nếu giữ như baseline gần

XII. Danh sách file CSV cuối cùng

Bảng V: Danh sách CSV cần nộp kèm để cập nhật bài báo.

File CSV	Mục đích
pilot_summary.csv	Khóa kết quả hiện tại: dense, learned-gate MoE, Cluster-MoE cosine/Euclidean, grid, temperature, Pi 5.
pretrained_backbone_results.csv	So sánh train-from-scratch và ImageNet-pretrained.
routing_entropy.csv	Báo cáo $\bar{H}$, entropy chuẩn hóa, usage CV theo model và τ .
expert_masking_ablation.csv	Bắt từng expert ở inference và đo suy giảm Accuracy/Macro-F1/per-class F1.
conditional_confusion_summary.csv	Many-tasks confusion theo primary expert.
seedwise_main_results.csv	Kết quả theo seed cho các cấu hình chính khi tăng seed.
paired_statistics_extended.csv	Paired test, confidence interval, effect size sau khi tăng seed.
power_analysis.csv	Ước lượng số seed cần thiết cho paired comparison.
cross_dataset_results.csv	Kết quả dataset độc lập.
backbone_generalization.csv	Kết quả với MobileNetV2/EfficientNet-B0 hoặc backbone thay thế.
soft_moe_baseline.csv	Baseline Soft MoE nếu được implement.
edge_runtime_results.csv	Runtime, memory, model size trên thiết bị biên.

XIII. Cách cập nhật bài báo

Sau khi có các CSV, cập nhật bài theo thứ tự sau. Trong phần Experimental Configuration, thêm pretrained state, dataset thứ hai, seed protocol, và backbone thay thế. Trong phần Results, thêm bảng pretrained, bảng entropy, bảng expert masking, bảng power analysis, bảng cross-dataset, và bảng backbone generalization. Trong phần Discussion, sửa claim theo bằng chứng: nếu paired tests vẫn không significant, viết “measured gain under the reported protocol”; nếu expert masking không cho suy giảm rõ, không dùng “specialization”, chỉ dùng “structured routing behavior”.

XIV. Điều kiện đủ để claim mạnh

Bài chỉ nên claim mạnh hơn khi đạt ít nhất bốn điều kiện. Thứ nhất, Cluster-MoE cosine vẫn cạnh tranh hoặc cải thiện với ImageNet-pretrained backbone. Thứ hai, routing entropy giải thích được điểm cân bằng $\tau = 0.5$. Thứ ba, expert masking cho thấy một số expert có tác động khác nhau lên nhóm class hoặc vùng feature. Thứ tư, kết quả với $n \geq 10$ seeds hoặc power analysis cho thấy kết luận thống kê được diễn giải đúng mức. Nếu thêm dataset độc lập hoặc backbone thay thế, phạm vi claim có thể mở từ tomato case study sang edge image classification có kiểm soát.

XV. Kết luận triển khai

Đợt mô phỏng bổ sung không cần chạy lại toàn bộ không gian tham số. Trọng tâm là kiểm chứng các điểm yếu có khả năng bị reviewer hỏi: pretrained backbone, dataset độc lập, statistical power, routing entropy, baseline/backbone mạnh hơn, và expert ablation. Khi các checkpoint trên hoàn tất, bài báo sẽ chuyển từ một kết quả pilot trên Tomato PlantDoc sang một đánh giá có kiểm soát cho clustered MoE routing trong edge image classification.